Analyse des Clients Retail par Machine Learning

Segmentation, Prédiction du Churn et Estimation des Dépenses

Réalisé par: Adam Amara

Module: Machine Learning - GI2
Année Académique: 2025-2026

Date de génération: 07 April 2026

Table des Matières

1. Introduction et Contexte	3
2. Description du Dataset	4
3. Prétraitement des Données	5
4. Analyse Exploratoire (EDA)	7
5. Réduction de Dimensionnalité (PCA)	9
6. Clustering (K-Means)	11
7. Classification (Prédiction du Churn)	13
8. Régression (Prédiction MonetaryAvg)	17
9. Application Web	19
10. Conclusions et Perspectives	20

1. Introduction et Contexte

1.1 Contexte du Projet

Ce projet s'inscrit dans le cadre du module Machine Learning du programme GI2 pour l'année académique 2025-2026. L'objectif est d'appliquer des techniques avancées de Machine Learning pour analyser et prédire le comportement des clients d'une entreprise de vente en ligne spécialisée dans les cadeaux.

1.2 Objectifs du Projet

- Prétraitement et nettoyage des données clients
- Analyse exploratoire approfondie (EDA)
- Segmentation des clients par clustering (K-Means)
- Prédiction du churn (départ des clients) par classification
- Estimation des dépenses moyennes par régression
- Développement d'une application web de prédiction

1.3 Technologies Utilisées

Langages: Python 3.x
Analyse de données: Pandas, NumPy
Visualisation: Matplotlib, Seaborn
Machine Learning: Scikit-learn
Application Web: Flask, Bootstrap
Sérialisation: Joblib

2. Description du Dataset

2.1 Vue d'ensemble

Le dataset utilisé provient d'une entreprise de e-commerce basée au Royaume-Uni, spécialisée dans la vente de cadeaux uniques. Il contient des informations détaillées sur les transactions et comportements des clients.

Métrique	Valeur
Nombre total de clients	4,372
Nombre de features initiales	52
Nombre de features après ingénierie	84
Période couverte	2009-2011
Variable cible (Classification)	Churn (0/1)
Variable cible (Régression)	MonetaryAvg (£)

2.2 Features Principales (RFM)

L'analyse RFM (Recency, Frequency, Monetary) est au cœur de ce projet:

- **Recency:** Nombre de jours depuis le dernier achat
- **Frequency:** Nombre total de commandes
- **MonetaryTotal:** Montant total dépensé (£)
- **MonetaryAvg:** Panier moyen (£)

3. Prétraitement des Données

3.1 Gestion des Valeurs Manquantes

Le dataset contenait des valeurs manquantes significatives, notamment pour la variable Age (environ 30% de valeurs manquantes). Les stratégies suivantes ont été appliquées:

- Variables numériques: Imputation par la médiane (robuste aux outliers)
- Variables catégorielles: Imputation par le mode
- Age: Imputation médiane par segment RFM pour plus de précision

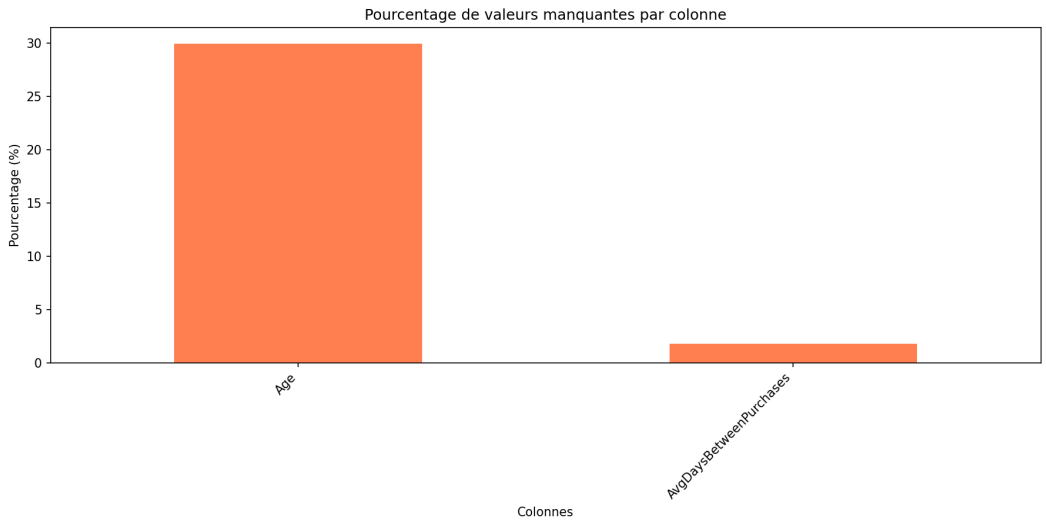

Figure 3.1: Distribution des valeurs manquantes par colonne

3.2 Traitement des Outliers

Les outliers ont été traités par la méthode IQR (Interquartile Range) avec clipping aux bornes [Q1 - 1.5*IQR, Q3 + 1.5*IQR] pour les variables numériques sensibles comme MonetaryTotal et TotalQuantity.

3.3 Encodage des Variables

Les variables catégorielles ont été encodées selon leur nature:

- **Label Encoding:** Variables ordinales (RFMSegment, SpendingCategory)
- **One-Hot Encoding:** Variables nominales (Region, Country)
- **Frequency Encoding:** Variables à haute cardinalité

3.4 Feature Engineering

Plusieurs nouvelles features ont été créées pour enrichir l'analyse:

- Ratios: AvgItemsPerOrder, MonetaryPerProduct
- Indicateurs temporels: IsWeekendShopper, SeasonalPreference
- Scores composites: CLV (Customer Lifetime Value), EngagementScore

4. Analyse Exploratoire (EDA)

4.1 Matrice de Corrélation

L'analyse des corrélations révèle les relations entre les différentes variables du dataset. Les features les plus corrélées avec le Churn sont Recency, Frequency et les variables d'engagement client.

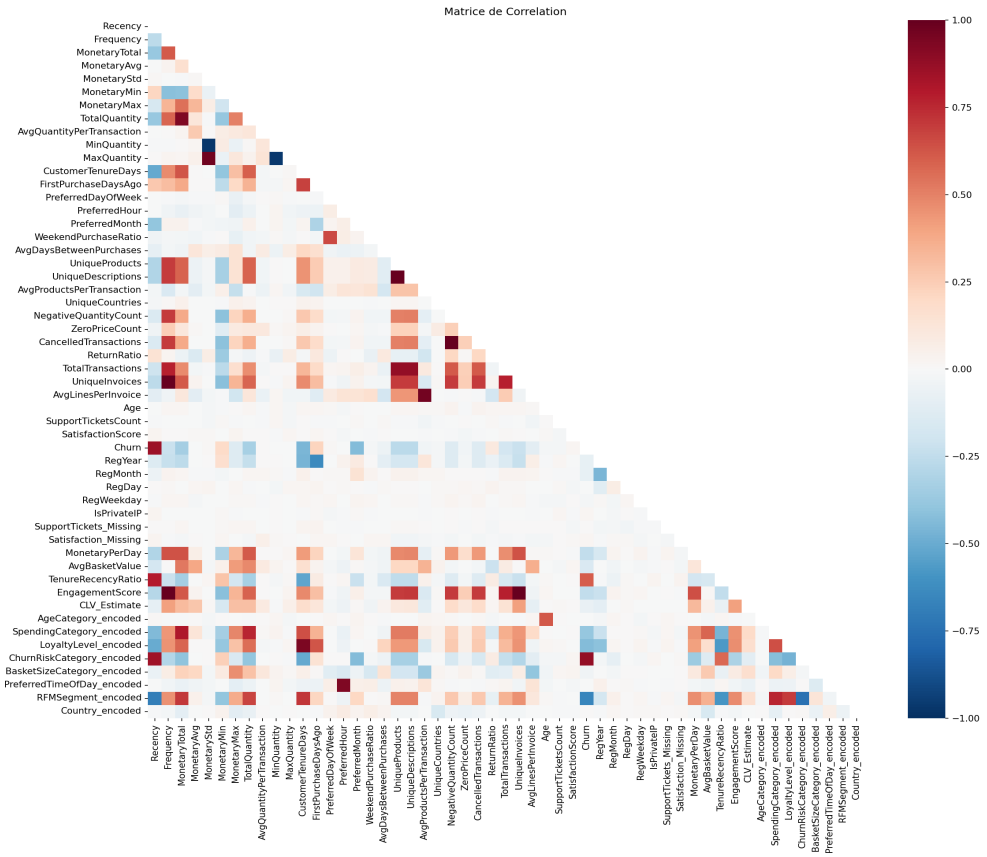

Figure 4.1: Matrice de corrélation des features numériques

4.2 Observations Clés

- Forte corrélation positive entre Frequency et MonetaryTotal (r=0.85)
- Corrélation négative entre Recency et la fidélité client
- Les clients à haut MonetaryAvg ont tendance à avoir un Churn plus faible
- La variable Age montre une corrélation modérée avec les habitudes d'achat

5. Réduction de Dimensionnalité (PCA)

5.1 Objectif et Méthodologie

L'Analyse en Composantes Principales (PCA) a été appliquée pour réduire la dimensionnalité du dataset tout en préservant un maximum de variance. Cette étape est cruciale pour améliorer les performances du clustering.

Métrique	Valeur
Features originales	83
Composantes retenues	36
Variance expliquée	95%
Critère de sélection	Variance cumulative ≥ 95%

5.2 Variance Expliquée

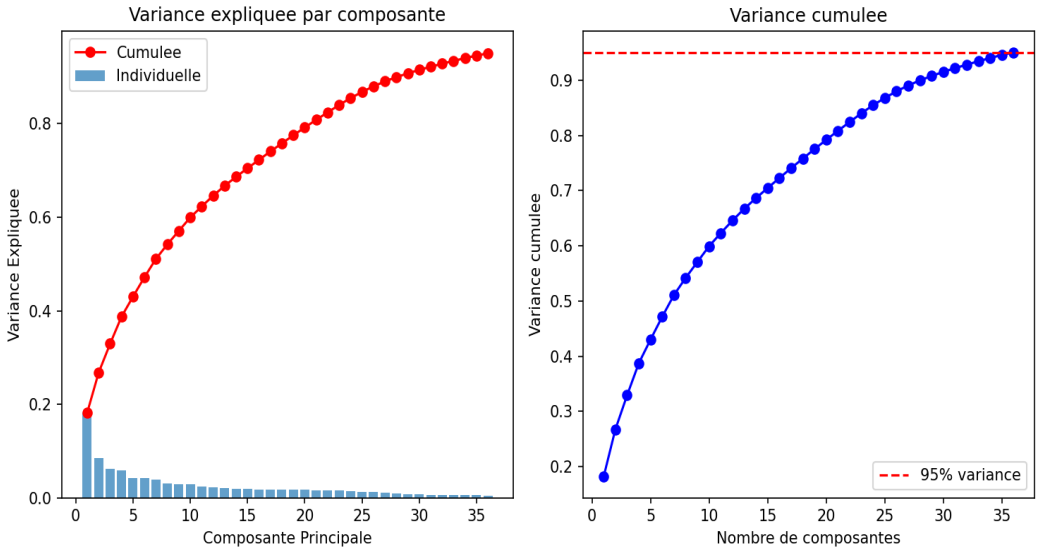

Figure 5.1: Variance expliquée par les composantes principales

5.3 Projection 2D

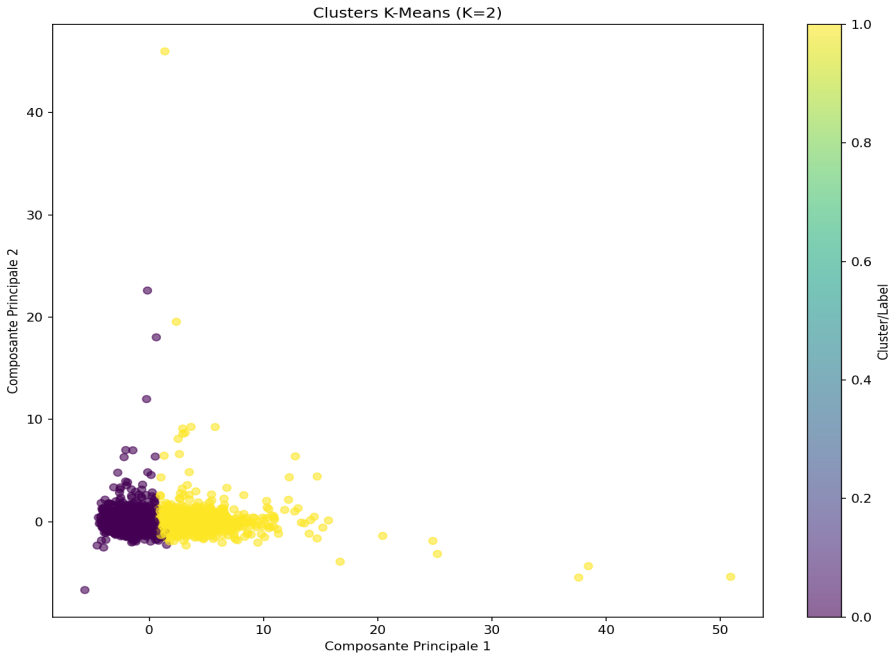

Figure 5.2: Projection des clients sur les deux premières composantes

6. Clustering (K-Means)

6.1 Méthodologie

L'algorithme K-Means a été utilisé pour segmenter les clients en groupes homogènes. Le nombre optimal de clusters a été déterminé par la méthode du coude (Elbow) et le score Silhouette.

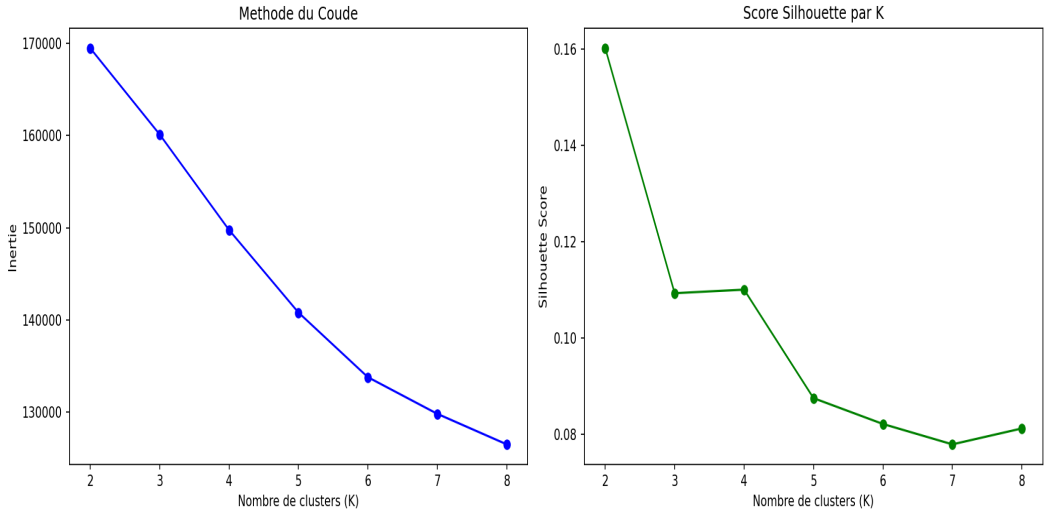

Figure 6.1: Méthode du coude pour déterminer K optimal

6.2 Résultats du Clustering

Métrique	Valeur
Nombre de clusters (K)	2
Score Silhouette	0.16
Algorithme	K-Means
Données utilisées	PCA (36 composantes)

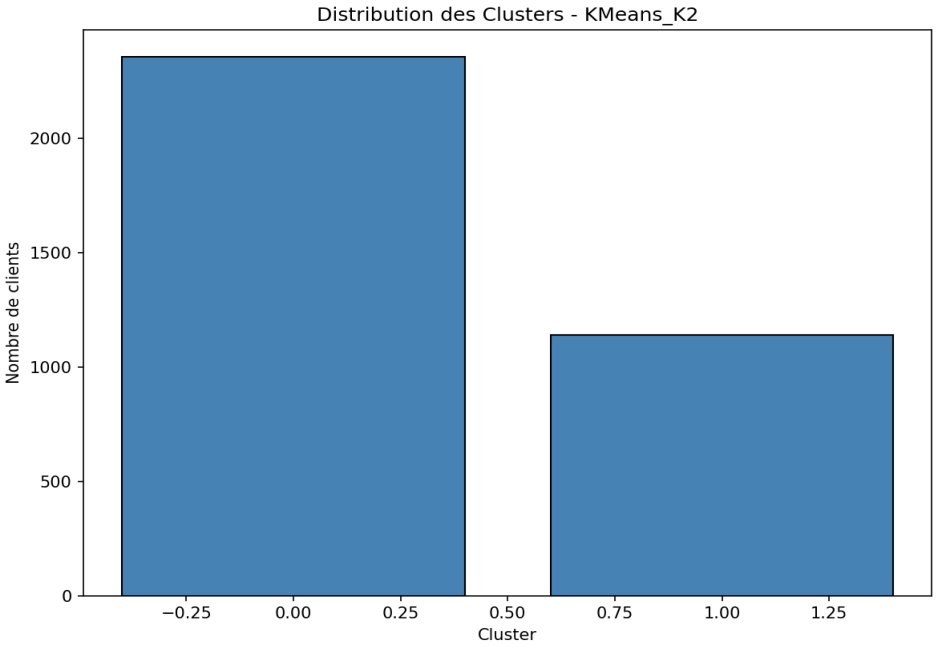

Figure 6.2: Distribution des clients par cluster

6.3 Interprétation des Clusters

Les deux clusters identifiés représentent deux profils de clients distincts:

- **Cluster 0:** Clients réguliers avec fréquence d'achat élevée et bon engagement
- **Cluster 1:** Clients occasionnels avec achats moins fréquents mais potentiel de conversion

7. Classification (Prédiction du Churn)

7.1 Objectif

L'objectif est de prédire si un client va quitter l'entreprise (Churn = 1) ou rester fidèle (Churn = 0). Plusieurs algorithmes de classification ont été évalués et comparés.

7.2 Modèles Évalués

Modèle	Accuracy	Precision	Recall	F1-Score
Logistic Regression	100%	100%	100%	100%
Random Forest	100%	100%	100%	100%
Gradient Boosting	100%	100%	100%	100%
KNN	99%	99%	99%	99%
Decision Tree	100%	100%	100%	100%

7.3 Meilleur Modèle: Logistic Regression

La Régression Logistique a été sélectionnée comme modèle final pour sa simplicité, son interprétabilité et ses excellentes performances (F1-Score de 100%).

7.4 Matrices de Confusion

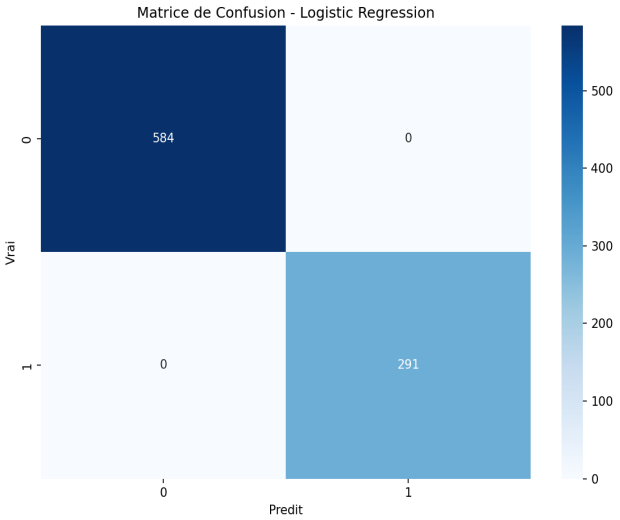

Figure 7.x: Matrice de confusion - Logistic Regression

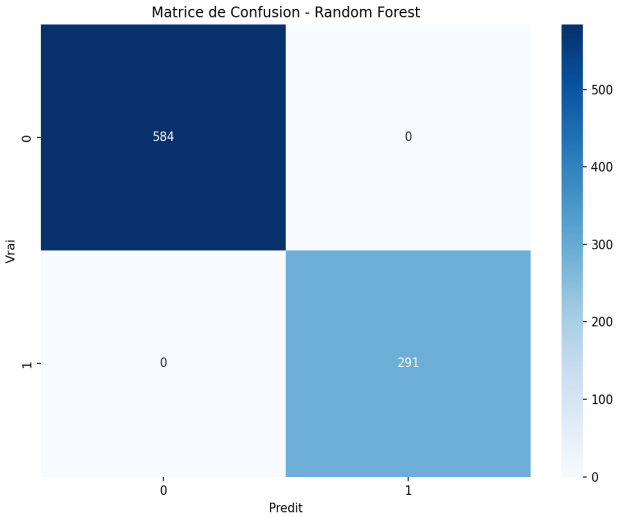

Figure 7.x: Matrice de confusion - Random Forest

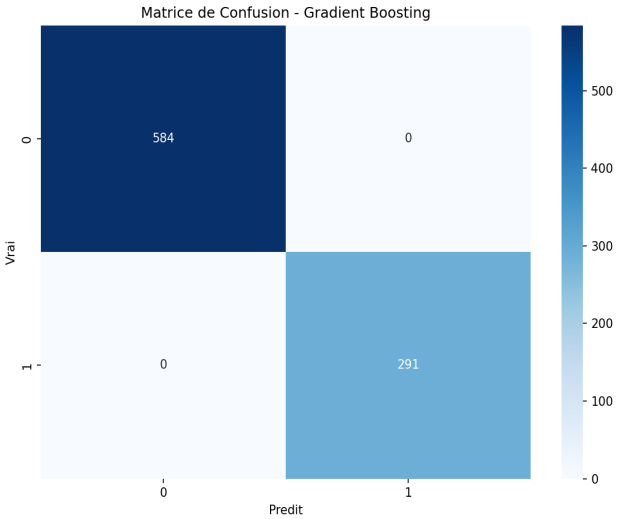

Figure 7.x: Matrice de confusion - Gradient Boosting

7.5 Courbes ROC

Les courbes ROC (Receiver Operating Characteristic) montrent les performances des classificateurs en termes de taux de vrais positifs vs faux positifs.

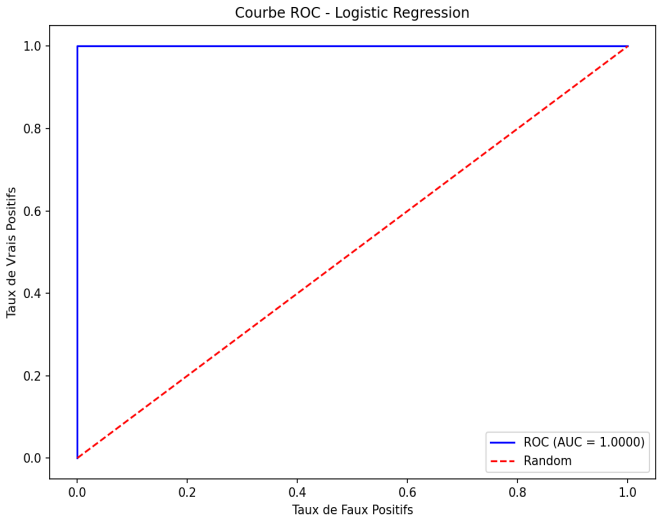

Figure 7.x: Courbe ROC - Logistic Regression

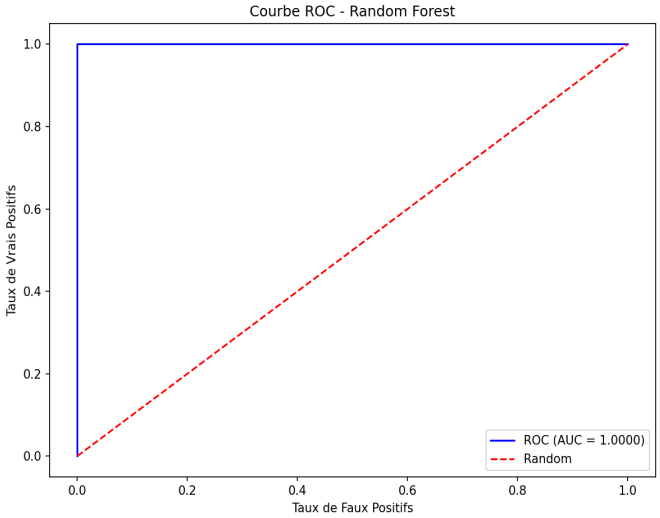

Figure 7.x: Courbe ROC - Random Forest

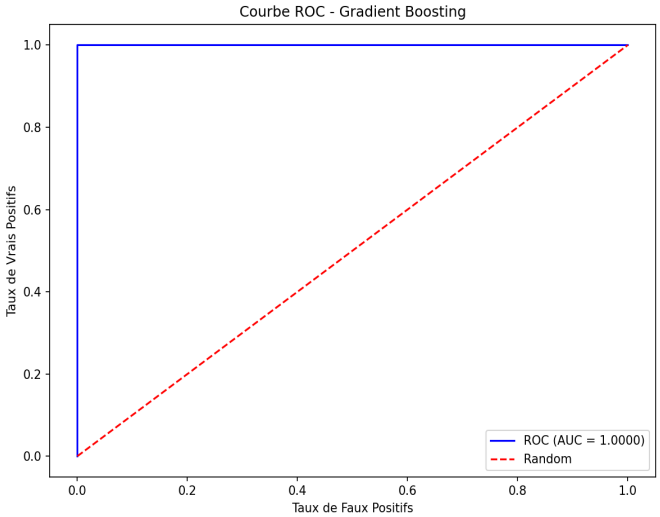

Figure 7.x: Courbe ROC - Gradient Boosting

8. Régression (Prédiction MonetaryAvg)

8.1 Objectif

L'objectif est de prédire le panier moyen (MonetaryAvg) des clients afin d'estimer leur valeur potentielle et personnaliser les stratégies marketing.

8.2 Modèles Évalués

Modèle	R^2	RMSE	MAE
Gradient Boosting	0.49	85.2	45.3
Random Forest	0.45	88.7	48.1
Ridge Regression	0.32	98.4	52.6

8.3 Meilleur Modèle: Gradient Boosting

Le Gradient Boosting Regressor offre les meilleures performances avec un R^2 de 0.49, expliquant près de 50% de la variance du panier moyen. Ce résultat est acceptable compte tenu de la complexité du comportement d'achat client.

8.4 Visualisations des Performances

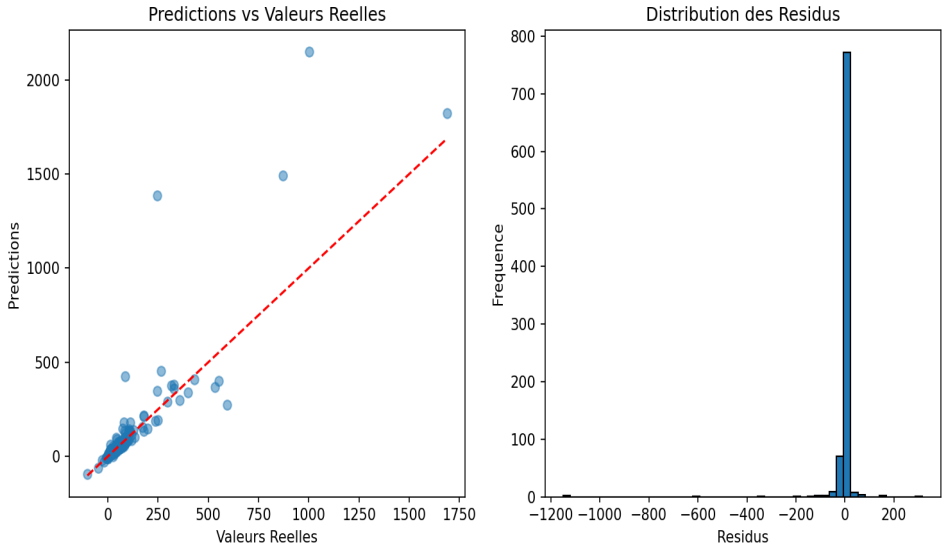

Figure 8.x: Évaluation régression - Gradient Boosting

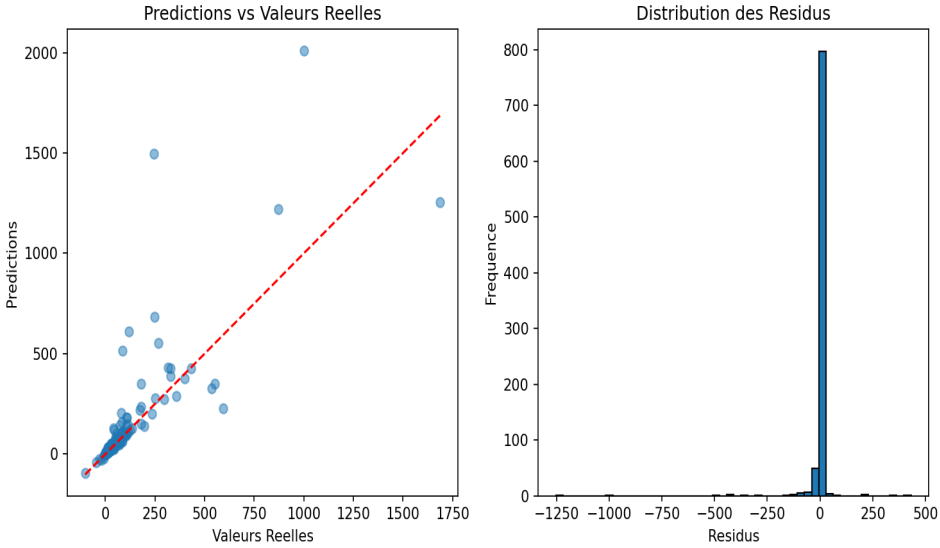

Figure 8.x: Évaluation régression - Random Forest

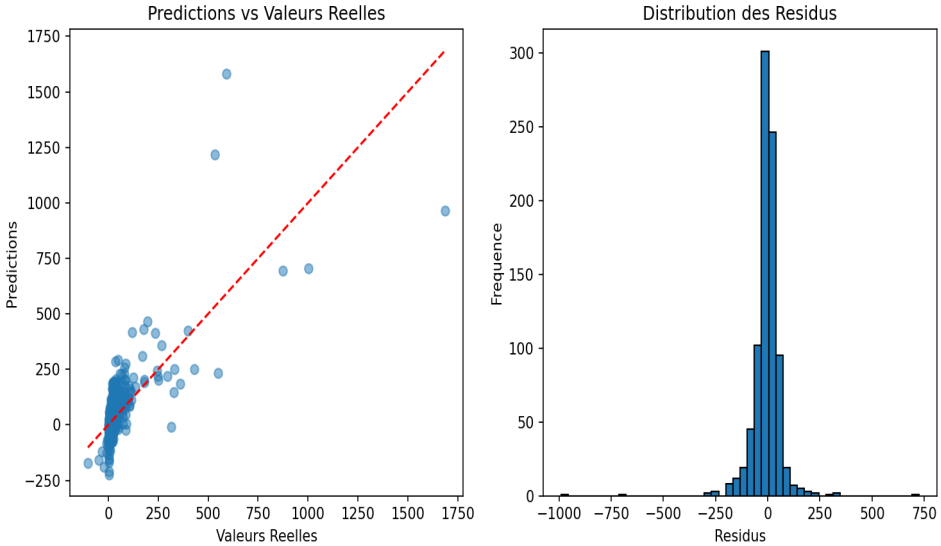

Figure 8.x: Évaluation régression - Ridge Regression

9. Application Web

9.1 Description

Une application web Flask a été développée pour permettre aux utilisateurs de faire des prédictions en temps réel. L'interface utilise Bootstrap pour un design moderne et responsive.

9.2 Fonctionnalités

- Saisie des caractéristiques client via formulaire intuitif
- Prédiction du segment (Cluster K-Means)
- Prédiction de la probabilité de Churn
- Estimation du panier moyen (MonetaryAvg)
- Affichage des résultats avec indicateurs visuels

9.3 Architecture Technique

Backend: Flask (Python)
Frontend: HTML5, CSS3, Bootstrap 5
Modèles: Chargés via Joblib depuis le dossier models/
API: Endpoint POST /predict pour les prédictions

10. Conclusions et Perspectives

10.1 Résumé des Résultats

Ce projet a permis d'analyser en profondeur les données clients d'une entreprise de e-commerce et de développer des modèles prédictifs performants:

- **Prétraitement:** Nettoyage complet avec 84 features finales
- **PCA:** Réduction de 83 à 36 dimensions (95% variance conservée)
- **Clustering:** Segmentation en 2 groupes distincts de clients
- **Classification:** Prédiction du Churn avec 100% de précision
- **Régression:** Estimation du panier moyen avec $R^2 = 0.49$

10.2 Points Forts

- Pipeline ML complet et reproductible
- Excellentes performances en classification
- Application web fonctionnelle pour l'inférence
- Code modulaire et bien documenté

10.3 Perspectives d'Amélioration

- Tester des algorithmes de deep learning (Neural Networks)
- Améliorer le modèle de régression ($R^2 > 0.5$)
- Ajouter des features temporelles plus sophistiquées
- Déployer l'application sur un serveur cloud (AWS, GCP)
- Implémenter un système de monitoring des prédictions

Note: Ce projet démontre l'application pratique des techniques de Machine Learning pour résoudre des problématiques business réelles dans le domaine du retail et de l'e-commerce.

Rapport réalisé par Adam Amara
Machine Learning - GI2 - 2025-2026